

# Disciplina: Aprendizado Profundo

## Aula 1: Introdução, Motivação e Fundamentos

Eliezer de Souza da Silva  
sereliezer.github.io  
eliezer.silva@ufc.br

Mestrado e Doutorado em Ciência da Computação, Universidade Federal do  
Ceará (MDCC / UFC)

8 de Setembro de 2025

# Roteiro da Aula de Hoje

- 1 O Curso e a Logística
- 2 A Trajetória Não-Linear do Deep Learning
- 3 Intuição e Fundamentos Matemáticos
- 4 Próximos Passos

# Oi mundo!

## Bem-vindos!

Meu nome é Eliezer. É um prazer tê-los aqui para explorarmos juntos as fronteiras do aprendizado profundo.

- Sou professor visitante no MDCC/UFC e pesquisador do Basque Center for Applied Mathematics (BCAM).

# Oi mundo!

## Bem-vindos!

Meu nome é Eliezer. É um prazer tê-los aqui para explorarmos juntos as fronteiras do aprendizado profundo.

- Sou professor visitante no MDCC/UFC e pesquisador do Basque Center for Applied Mathematics (BCAM).
- Pesquisa foca em aprendizado de máquina probabilístico, métodos Bayesianos e modelos generativos. Ph.D. em Ciência da Computação pela NTNU, Mestre pela FEEC/Unicamp e Bacharel pela UFES (Eng. Comp.).

# Oi mundo!

## Bem-vindos!

Meu nome é Eliezer. É um prazer tê-los aqui para explorarmos juntos as fronteiras do aprendizado profundo.

- Sou professor visitante no MDCC/UFC e pesquisador do Basque Center for Applied Mathematics (BCAM).
- Pesquisa foca em aprendizado de máquina probabilístico, métodos Bayesianos e modelos generativos. Ph.D. em Ciência da Computação pela NTNU, Mestre pela FEEC/Unicamp e Bacharel pela UFES (Eng. Comp.).
- Estou animado para conhecer vocês, os seus interesses e contribuir com o aprendizado de todos.

# Oi mundo!

## Bem-vindos!

Meu nome é Eliezer. É um prazer tê-los aqui para explorarmos juntos as fronteiras do aprendizado profundo.

- Sou professor visitante no MDCC/UFC e pesquisador do Basque Center for Applied Mathematics (BCAM).
- Pesquisa foca em aprendizado de máquina probabilístico, métodos Bayesianos e modelos generativos. Ph.D. em Ciência da Computação pela NTNU, Mestre pela FEEC/Unicamp e Bacharel pela UFES (Eng. Comp.).
- Estou animado para conhecer vocês, os seus interesses e contribuir com o aprendizado de todos.
- Página: <https://sereliezer.github.io/>
- Email: [eliezer.silva@ufc.br](mailto:eliezer.silva@ufc.br)

# O Processo de Aprendizagem

## Terence Tao sobre o Aprendizado em Matemática

O ilustre matemático no post “Existe mais do que rigor e provas na matemática” apresenta um *processo cíclico* composto de estágios:

# O Processo de Aprendizagem

## Terence Tao sobre o Aprendizado em Matemática

O ilustre matemático no post “Existe mais do que rigor e provas na matemática” apresenta um *processo cíclico* composto de estágios:

- **Pré-formal:** Temos intuições, uma atitude lúdica, curiosa e aberta.



# O Processo de Aprendizagem

## Terence Tao sobre o Aprendizado em Matemática

O ilustre matemático no post “Existe mais do que rigor e provas na matemática” apresenta um *processo cíclico* composto de estágios:

- **Pré-formal:** Temos intuições, uma atitude lúdica, curiosa e aberta.
- **Formal:** Buscamos desenvolver conhecimento rigoroso, de forma paulatina e cautelosa.

# O Processo de Aprendizagem

## Terence Tao sobre o Aprendizado em Matemática

O ilustre matemático no post “Existe mais do que rigor e provas na matemática” apresenta um *processo cíclico* composto de estágios:

- **Pré-formal:** Temos intuições, uma atitude lúdica, curiosa e aberta.
- **Formal:** Buscamos desenvolver conhecimento rigoroso, de forma paulatina e cautelosa.
- **Pós-formal:** "Esquecemos" os formalismos e reaprendemos a partir dos fundamentos, conectando cada intuição a um formalismo e vice-versa.

# Apresentação do Curso I

## Estrutura da Disciplina

- **Objetivo:** Construir uma base teórica e prática sólida em redes neurais modernas.
- **Metodologia:** Desenvolver aprendizado em diferentes frentes – Modelagem, Teoria, Técnica e Aplicações. Participação ativa, perspectiva crítica e um “olhar de pesquisa”.
- **Comunicação:** Usaremos o SIGAA para notícias, materiais e entregas.

# Avaliação e Logística I

## Método de Avaliação

O foco é 100% no aprendizado contínuo, integrado e prático. **Não haverá provas.**

- **Listas de Exercícios (60%):**  $N$  ( $N > 3$ ) listas teórico-práticas. Alguns laboratórios contarão como listas práticas. Detalhes ainda a definir.
- **Projeto Final (40%):** Mini-projeto de pesquisa em grupos de 3, com duas entregas parciais e um seminário final.

# Avaliação e Logística II

## Logística Híbrida

- **Presencial:** Setembro, Dezembro e Janeiro.
- **Remoto:** Outubro e Novembro.

## Feedback sobre as aulas

Feedback é necessário para aprendizado. Disponibilizarei um link para feedback anônimo, mas sintam-se à vontade para falar abertamente comigo.

# Livros-Texto e Leitura Complementar I

## Livros-Texto Principais

Estes livros formam a base da nossa disciplina.

- Christopher M. Bishop e Hugh Bishop (2023). *Deep Learning: Foundations and Concepts*. Springer
- Simon J.D. Prince (2023). *Understanding Deep Learning*. The MIT Press
- Kevin Patrick Murphy (2023). *Probabilistic Machine Learning: Advanced Topics*. The MIT Press
- Christopher M. Bishop (2006). *Pattern Recognition and Machine Learning*. Springer

# Livros-Texto e Leitura Complementar II

## Leitura Complementar Sugerida

Para aprofundar em tópicos específicos que discutiremos.

- Sam Buchanan et al. (ago. de 2025). *Learning Deep Representations of Data Distributions*.  
<https://ma-lab-berkeley.github.io/deep-representation-learning-book/>. Online
- Peter D. Grünwald (2007). *The Minimum Description Length Principle*. The MIT Press
- Andreas Krause e Jonas Hübotter (2025). *Probabilistic Artificial Intelligence*. arXiv: 2502.05244 [cs.AI]

# O Impacto do Deep Learning no Mundo Real I

## Por que estudar Redes Neurais agora?

Estamos vivendo uma revolução tecnológica impulsionada por avanços em arquiteturas de redes neurais.

- **Redes Convolucionais (CNNs):** Dominaram a **Visão Computacional**.
  - *Aplicações:* Carros autônomos, diagnóstico médico por imagem, reconhecimento facial.
- **Transformers:** A arquitetura que define a era da **IA moderna**.
  - *Aplicações:* NLP (*ChatGPT, BERT*), tradução, bioinformática (*AlphaFold*).



# O Impacto do Deep Learning no Mundo Real II

- **Modelos Generativos (GANs, Difusão):** Criam dados novos e realistas.
  - *Aplicações:* Geração de imagens, vídeos e arte (*Midjourney*, *Dall-e*), extração de conhecimento.

# A Revolução Está Apenas Começando I

## O Futuro: Desafios Abertos

Apesar do sucesso, os maiores desafios ainda estão por vir. A próxima geração de avanços irá além das tarefas atuais.

# A Revolução Está Apenas Começando II

## De Padrões a Sistemas Complexos

Precisamos ir além de “simplesmente” reconhecer padrões para resolver problemas de larga escala na engenharia e na sociedade:

- **Engenharia:** Design autônomo de materiais, controle de redes elétricas inteligentes, sistemas logísticos globais.
- **Ciência:** Modelagem climática, simulação de sistemas biológicos complexos, raciocínio matemático automatizado.
- **Sociedade:** Sistemas de ensino personalizados, otimização de políticas públicas, medicina de precisão.

# O Objetivo Deste Curso: De Usuário a Criador I

## 1. Entender os Princípios de Design

O objetivo é saber **como construir**.

- Escolher a **arquitetura correta**.
- Entender **trade-offs** (custo vs. performance).
- Diagnosticar e **depurar** modelos.
- Criar soluções **inovadoras**.

## 2. Avaliar Capacidades e Limitações

Desenvolver um olhar crítico para saber **o que é possível**.

- Quando DL é a ferramenta **certa**?
- Reconhecer modos de falha (alucinações).
- Avaliar modelos além da acurácia: robustez, ética e interpretabilidade.

# O Objetivo Deste Curso: De Usuário a Criador II

## Leitura Adicional

Para uma visão crítica sobre os desafios futuros da IA:

[Michael I Jordan \(2019\)](#). “Artificial intelligence—the revolution hasn’t happened yet”. Em: *Harvard Data Science Review* 1.1


# As Sementes Intelectuais I: Computação e Aprendizado I

## Alan Turing (1948): "Intelligent Machinery"

Neste ensaio, Turing foi além da computabilidade e explorou como uma máquina poderia aprender. Turing 1969

- Ele propôs as "**máquinas não-organizadas**" (unorganised machines).
- Eram redes de **circuitos lógicos** simples (e.g., portas NAND) interconectados aleatoriamente.
- A ideia central: um sistema desorganizado poderia, através de "interferência apropriada" (treinamento), se tornar organizado.

# As Sementes Intelectuais I: Computação e Aprendizado II



**Figura:** Ilustração da B-Type Network de Turing, uma precursora das redes neurais.

## Leitura Adicional

Para aprofundar sobre as ideias de Turing

Alan M. Turing (1969). "Intelligent Machinery". Em: *Machine Intelligence 5*. Ed. por Bernard Meltzer e Donald Michie. Edinburgh University Press, pp. 3–23


# As Sementes Intelectuais II: Conexões Interdisciplinares I

## Cibernética

**Wiener, McCulloch & Pitts (anos 40-50):** A ideia de que sistemas (biológicos ou artificiais) podem aprender e se auto-regular através de *feedback*. Criaram o primeiro modelo matemático do neurônio.

## Conexionismo e Ciências Cognitivas

Nos anos 80, o connexionismo ressurgiu como alternativa ao simbolismo, postulando que a inteligência emerge da interação de muitas unidades simples e interconectadas.



O "Teseu" de Shannon (1950), um rato artificial que aprendia a navegar em um labirinto.



# As Sementes Intelectuais II: Conexões Interdisciplinares II

## Leitura Adicional

Artigo trazendo uma narrativa detalhada da vida e obra de Pitts e sua relação com McCulloch e outros intelectuais da sua época

Amanda Gefter (fev. de 2015). “The Man Who Tried to Redeem the World with Logic”. Em: *Nautilus*. URL:

<https://nautil.us/the-man-who-tried-to-redeem-the-world-with-logic-235253/>

## Teoria da Informação

**Claude Shannon (1948):** Formalizou o conceito de *informação* e entropia. Nossos modelos aprendem para extrair informação dos dados e reduzir a incerteza sobre uma previsão.

## As Sementes Intelectuais II: Conexões Interdisciplinares III

### Leitura Adicional

Artigo seminal que fundamenta a área de Teoria de Informação

Claude E. Shannon (1948). *A Mathematical Theory of Communication*. Vol. 27, pp. 379–423, 623–656

# Visão Panorâmica dos Fundamentos

## O Que Vamos Explorar

Nessa seção, iremos explorar de forma conceitual os fundamentos matemáticos necessários, construindo uma intuição sólida.

- Teoria do Aprendizado Estatístico
- Teoria da Probabilidade
- Teoria da Informação
- Teoria da Otimização (próximas aulas)

# Fundamento 1: Teoria do Aprendizado Estatístico I

## O Espaço de Hipóteses e o Risco

- O espaço de funções que exploramos é o **espaço de hipóteses**,  $\mathcal{H}$ .
- O aprendizado consiste em escolher uma hipótese  $h \in \mathcal{H}$  que generalize bem para dados não vistos.
- **Risco Empírico ( $\hat{R}$ )**: O erro que medimos no conjunto de treino.
- **Risco Real ( $R$ )**: O erro esperado na distribuição real dos dados (o que realmente queremos minimizar).

# Fundamento 1: Teoria do Aprendizado Estatístico II

## Espaços de Funções/Hipóteses ( $\mathcal{H}$ )

Onde procuramos por  $h$ ? Em uma classe de modelos (ou espaço de funções)  $\mathcal{H}$ .

- **Regressão Linear:**  $\mathcal{H}$  é o espaço de funções lineares  
$$h(x) = w^\top x.$$
- **Redes Neurais:**  $\mathcal{H}$  é um espaço vasto e altamente expressivo de funções não-lineares.

O “aprendizado” é um processo de **busca** pela função  $h^* \in \mathcal{H}$  que satisfaça alguns critérios.

# Fundamento 1: Teoria do Aprendizado Estatístico III

## O Dilema Central

Queremos minimizar o Risco Real, mas só podemos calcular o Risco Empírico. A diferença entre eles é o **gap de generalização**, e seu tamanho depende da complexidade do espaço de hipóteses  $\mathcal{H}$ .

# Mergulho Raso: Minimum Description Length (MDL) I

## O Princípio MDL: Aprendizado como Compressão

A melhor hipótese (modelo) para explicar um conjunto de dados é aquela que permite a **compressão máxima** dos dados, resultando na descrição mais curta possível.

# Mergulho Raso: Minimum Description Length (MDL) II

## O Código de Duas Partes e a Navalha de Occam


O comprimento total da descrição dos dados  $D$  é a soma do comprimento da descrição da hipótese  $H$  e do comprimento da descrição dos dados codificados com a ajuda de  $H$ :

$$L(D) \approx \underbrace{L(H)}_{\text{Complexidade do Modelo}} + \underbrace{L(D|H)}_{\text{Ajuste aos Dados (Erro)}}$$

A complexidade  $L(H)$  pode ser entendida como o **tamanho do programa** que implementa o modelo. A Indução de Solomonoff formaliza isso, postulando que a melhor previsão é uma média de todos os programas que geram os dados, com peso maior para os programas **mais curtos**.



# Mergulho Raso: Minimum Description Length (MDL) III



**Figura:** MDL busca o balanço: um modelo muito simples não captura os dados; um modelo muito complexo custa caro para ser descrito (um "programa" longo) e não generaliza.

## Fundamento 2: A Linguagem da Incerteza - Probabilidade I

### Axiomas da Probabilidade (Kolmogorov)

A teoria da probabilidade é uma extensão da lógica, construída sobre 3 axiomas:

- 1 A probabilidade de um evento é não-negativa:  $P(A) \geq 0$ .
- 2 A probabilidade do espaço amostral (evento certo) é 1:  
 $P(\Omega) = 1$ .
- 3 A probabilidade da união de eventos disjuntos é a soma de suas probabilidades.

A partir destes, derivamos as regras de soma e produto.

## Fundamento 2: A Linguagem da Incerteza - Probabilidade II

### Modelos Gráficos e Independência

- Permitem representar distribuições complexas sobre muitas variáveis de forma compacta, codificando suposições de **independência condicional**.
- Exemplo (Rede Bayesiana):  $A \rightarrow B \rightarrow C$ . A distribuição conjunta fatoriza:

$$p(A, B, C) = p(A)p(B|A)p(C|B)$$

- Redes neurais profundas podem ser vistas como um tipo de modelo gráfico, onde as camadas representam variáveis latentes.

# Regras Fundamentais da Probabilidade I

## Regra do Produto e da Soma

A partir dos axiomas, derivamos duas regras essenciais:

- **Regra da Soma:**  $p(X) = \sum_Y p(X, Y)$  (Marginalização)
- **Regra do Produto:**  $p(X, Y) = p(Y|X)p(X) = p(X|Y)p(Y)$

# Regras Fundamentais da Probabilidade II

## A Regra de Bayes

Combinando as duas formas da regra do produto, obtemos a Regra de Bayes, fundamental para o aprendizado:

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

$$\text{Posterior} = \frac{\text{Verossimilhança} \times \text{Prior}}{\text{Evidência}}$$

Ela nos permite "inverter" a inferência: a partir do que observamos ( $X$ ), atualizamos nossa crença sobre o que não vemos ( $Y$ ).

# Distribuições Típicas e Momentos I

## Momentos de uma Distribuição

Momentos descrevem a forma de uma distribuição. Os mais importantes são:

- **Média (1º Momento):** O valor esperado.  $\mathbb{E}[X] = \int xp(x)dx$
- **Variância (2º Momento Central):** A dispersão em torno da média.  $\text{var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$

# Distribuições Típicas e Momentos II

## Distribuições de Probabilidade Comuns

- **Gaussiana (Normal):** Usada para modelar quantidades contínuas (e.g., erros em regressão).

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- **Bernoulli:** Usada para modelar um evento binário (e.g., classificação com duas classes).

$$\text{Bern}(x|\mu) = \mu^x(1 - \mu)^{1-x} \quad \text{para } x \in \{0, 1\}$$

# O Princípio da Máxima Verossimilhança (MLE) I

Como encontrar os melhores pesos  $w$ ? Escolhemos aqueles que tornam os dados observados  $\mathcal{D}$  os mais prováveis.

## A Função de Verossimilhança (Likelihood)

Assumindo que os dados são i.i.d., a probabilidade de todo o conjunto de dados de alvos  $y = \{y_1, \dots, y_N\}$  é:

$$p(y|X, w) = \prod_{n=1}^N p(y_n|x_n, w)$$

O objetivo do **Maximum Likelihood Estimation (MLE)** é encontrar os pesos  $w_{\text{ML}}$  que maximizam esta função C. M. Bishop e H. Bishop 2023.



# O Princípio da Máxima Verossimilhança (MLE) II

## Log-Likelihood

Na prática, maximizamos o logaritmo da verossimilhança, que transforma o produto em uma soma e é numericamente mais estável:

$$\ln p(y|X, w) = \sum_{n=1}^N \ln p(y_n|x_n, w)$$

# De Máxima Verossimilhança a Funções de Custo I

Maximizar o log-likelihood é equivalente a **minimizar o negativo do log-likelihood (NLL)**.

## Regressão (Likelihood Gaussiano) → Erro Quadrático

Assumindo que o alvo  $y_n$  é a saída da rede  $g(x_n, w)$  mais um ruído Gaussiano, temos  $p(y_n|x_n, w) = \mathcal{N}(y_n|g(x_n, w), \sigma^2)$ . O NLL do dataset é:

$$-\ln p(y|X, w) = \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - g(x_n, w))^2 + \frac{N}{2} \ln(2\pi\sigma^2)$$

Minimizar isso em relação a  $w$  é o mesmo que minimizar o **erro da soma dos quadrados (sum-of-squares error)**.

# De Máxima Verossimilhança a Funções de Custo II

## Classificação (Likelihood de Bernoulli) $\rightarrow$ Cross-Entropy

Para um alvo binário  $y_n \in \{0, 1\}$ , assumimos

$p(y_n|x_n, w) = \text{Bern}(y_n|g(x_n, w))$ . O NLL é:

$$-\ln p(y|X, w) = -\sum_{n=1}^N \{y_n \ln g(x_n, w) + (1 - y_n) \ln(1 - g(x_n, w))\}$$

Esta é exatamente a função de custo de **entropia cruzada binária** (**binary cross-entropy**).

## Fundamento 3: Teoria da Informação I

### Mergulho Raso: De Onde Vem o Logaritmo na Entropia?

Queremos uma função  $S(p)$  que meça a "surpresa" de um evento com probabilidade  $p$ . Intuitivamente, ela deve satisfazer:

- 1 Surpresa é não-negativa e decresce com  $p$ .
- 2 A surpresa de dois eventos **independentes** ocorrendo juntos é a **soma** de suas surpresas individuais:

$$S(p_1 \cdot p_2) = S(p_1) + S(p_2)$$

A única família de funções que satisfaz a propriedade aditiva (2) é a logarítmica,  $S(p) = -C \log(p)$ . A Entropia é, portanto, a surpresa média de uma distribuição,  $\mathbb{E}[S(p(X))]$ .

## Fundamento 3: Teoria da Informação II

### Entropia

Para uma variável aleatória  $X$  com função de probabilidade  $p$ , a entropia mede a “surpresa” média Claude E. Shannon 1948:

$$H(p) = - \sum_{k=1}^K p(x_k) \log_2 p(x_k)$$

É a quantidade média de informação (em bits) que ganhamos ao observar uma amostra de  $X$ .

- Uma moeda honesta ( $P(\text{cara}) = 0.5$ ) tem entropia máxima (1 bit). Cada resultado é igualmente surpreendente.
- Uma moeda viciada ( $P(\text{cara}) = 0.99$ ) tem entropia próxima de zero, então não há surpresa.

## Fundamento 3: Teoria da Informação III

### Divergência KL e Cross-Entropy

A **Divergência Kullback-Leibler (KL)** mede a dissimilaridade entre duas distribuições  $p$  e  $q$ :

$$\text{KL}(P||Q) = - \sum_{k=1}^K p(x_k) \log_2 \left( \frac{q(x_k)}{p(x_k)} \right) \geq 0$$

Isso nos leva à **Cross-Entropy**,  $H(p, q)$ , que é a base para a função de custo em classificação. Minimizar a cross-entropy é equivalente a minimizar a divergência KL entre a distribuição real dos dados ( $P$ ) e a previsão do nosso modelo ( $Q$ ) C. M. Bishop 2006.

$$H(P, Q) = H(P) + \text{KL}(P||Q)$$

# Anatomia de uma Rede Neural I

## Blocos de Construção

Uma rede neural é um **grafo computacional** composto em camadas, onde cada neurônio (ou unidade) realiza uma operação simples:

- **Transformação Linear:** Uma soma ponderada das entradas, mais um viés.  $z = w^T x + b$
- **Função de Ativação:** Uma transformação não-linear aplicada ao resultado.  $a = \sigma(z)$

Os **pesos** ( $w$ ) e **vieses** ( $b$ ) são os parâmetros que o modelo aprende durante o treinamento.

# Anatomia de uma Rede Neural II

## Composição em Camadas

A saída de uma camada de neurônios,  $a^{(l)} = \sigma(W^{(l)}a^{(l-1)} + b^{(l)})$ , serve como entrada para a próxima. Essa composição hierárquica é o que permite que redes profundas aprendam representações (features) cada vez mais complexas dos dados.



# Aproximação de Funções com Funções de Base I

## A Ideia Central da Teoria da Aproximação

Qualquer função “bem comportada” pode ser representada como uma **soma ponderada** de um conjunto de funções mais simples (as “funções de base”  $\phi_i$ ).

$$g(x) = \sum_{i=1}^M w_i \phi_i(x)$$

Exemplos clássicos de funções de base:

- **Polinômios:** Base para a expansão em Série de Taylor.
- **Senos e Cossenos:** Base para a representação em Série de Fourier.

# Aproximação de Funções com Funções de Base II

- **Funções Radiais de Base (RBFs):** Usadas em SVMs e outros métodos.

## Conexão com Redes Neurais

Uma camada de uma rede neural calcula uma combinação linear (soma ponderada) das saídas da camada anterior. Essas saídas atuam como **funções de base não-lineares que são aprendidas** a partir dos dados, em vez de serem fixas. Portanto a classe de modelos com funções de base  $g(x) = \sum_{i=1}^M w_i \phi_i(x)$  define uma **rede neural rasa**, ou seja, de apenas uma ou poucas camadas.

# Exemplo Prático: Rede Rasa vs. Aprendizado de Features I

Para ilustrar a diferença entre bases fixas e bases aprendidas, vamos analisar um exemplo prático.

## Laboratório Interativo no Google Colab

O código completo para este exemplo está disponível como um notebook interativo. Recomendo que todos abram e executem o código para explorar os resultados.

[Abrir Notebook no Colab](#)


# Exemplo Prático: Rede Rasa vs. Aprendizado de Features II

## Objetivo do Experimento


Vamos tentar aproximar um polinômio desconhecido usando uma rede RBF de duas maneiras:

- 1 Modelo 1 (Raso):** Centros e larguras das RBFs são fixos. Apenas os pesos da camada final são aprendidos (via Mínimos Quadrados).
- 2 Modelo 2 (Deep-like):** Centros, larguras e pesos são todos aprendidos simultaneamente via Descida de Gradiente.

# Resultados do Experimento



**Figura:** Passo 1: Geramos 100 pontos de dados com ruído a partir de um polinômio aleatório (a "verdade" que queremos descobrir).



**Figura:** Passo 2: O modelo de bases aprendidas (azul) se ajusta muito melhor à função verdadeira do que o modelo de bases fixas (vermelho).

## Conclusão do Exemplo: A Formulação

A rede RBF implementada tem a seguinte forma:

$$g(x) = \sum_{i=1}^M w_i \phi_i(x) + w_0 \text{ onde } \phi_i(x) = \exp\left(-\frac{(x - c_i)^2}{2\sigma_i^2}\right)$$

### Modelo 1

Os parâmetros das funções de base  $(c_i, \sigma_i)$  são **fixos**. O aprendizado se resume a encontrar os pesos  $w$  que resolvem um problema de Mínimos Quadrados. A não-linearidade é pré-definida, não aprendida.

### Modelo 2

Os parâmetros das funções de base  $(c_i, \sigma_i)$  **também são aprendidos** via otimização. A rede descobre as representações (ou features) mais eficientes diretamente a partir dos dados.

# O Mapa do Nosso Curso

## Nossa Jornada

Vamos explorar diferentes formas de construir o espaço de hipóteses  $\mathcal{H}$ :

- 1 Começaremos com o **Perceptron**, a unidade mais básica.
- 2 Construiremos **FNNs** para aproximação de funções gerais.
- 3 Especializaremos para diferentes tipos de dados:
  - Sequências com **RNNs** e **Transformers**.
  - Grafos com **GNNs**.
- 4 Exploraremos modelos que aprendem a própria distribuição dos dados  $p(x)$  para gerar amostras novas (**Modelos Generativos**).

# Encerramento e Perguntas

## Para a Próxima Aula (Quarta-feira)

- **Tópico:** O Perceptron e a Descida de Gradiente.
- **Objetivo:** Implementar nosso primeiro algoritmo de aprendizado.






## Tarefa

- Comecem a pensar e a formar os **grupos de 3 pessoas** para o projeto final.







Perguntas?






# Referências I

-  Bishop, Christopher M. (2006). *Pattern Recognition and Machine Learning*. Springer.
-  Bishop, Christopher M. e Hugh Bishop (2023). *Deep Learning: Foundations and Concepts*. Springer.
-  Buchanan, Sam et al. (ago. de 2025). *Learning Deep Representations of Data Distributions*.  
<https://ma-lab-berkeley.github.io/deep-representation-learning-book/>. Online.
-  Gefter, Amanda (fev. de 2015). “The Man Who Tried to Redeem the World with Logic”. Em: *Nautilus*. URL:  
<https://nautil.us/the-man-who-tried-to-redeem-the-world-with-logic-235253/>.
-  Grünwald, Peter D. (2007). *The Minimum Description Length Principle*. The MIT Press.

## Referências II

-  Jordan, Michael I (2019). “Artificial intelligence—the revolution hasn’t happened yet”. Em: *Harvard Data Science Review* 1.1.
-  Krause, Andreas e Jonas Hübner (2025). *Probabilistic Artificial Intelligence*. arXiv: 2502.05244 [cs.AI].
-  Minsky, Marvin e Seymour A Papert (1969). *Perceptrons: An introduction to computational geometry*. MIT press.
-  Murphy, Kevin Patrick (2023). *Probabilistic Machine Learning: Advanced Topics*. The MIT Press.
-  Prince, Simon J.D. (2023). *Understanding Deep Learning*. The MIT Press.
-  Rosenblatt, Frank (1958). “The perceptron: a probabilistic model for information storage and organization in the brain.”. Em: *Psychological review* 65.6, p. 386.

## Referências III

-  Shannon, C. E. (1988). “Programming a computer for playing chess”. Em: *Computer Chess Compendium*. Berlin, Heidelberg: Springer-Verlag, pp. 2–13. ISBN: 0387913319.
-  Shannon, Claude E. (1948). *A Mathematical Theory of Communication*. Vol. 27, pp. 379–423, 623–656.
-  Turing, Alan M. (1969). “Intelligent Machinery”. Em: *Machine Intelligence 5*. Ed. por Bernard Meltzer e Donald Michie. Edinburgh University Press, pp. 3–23.